

Park Jimin


클라우드 인프라 · 데이터 파이프라인 · 데이터 엔지니어링



qwa8418@naver.com



010-2627-8418



<https://github.com/jimin-park-01>

01 **PROFILE**

소개 및 기술역량

02 **KEY PROJECTS**

주요 프로젝트

- 1 광고 Attribution Lakehouse 플랫폼 구축
- 2 농산물 시장 종합 모니터링 대시보드
- 3 3-Tier 인프라 환경 구축

03 **SUPPORTING PROJECTS**

보조 프로젝트

- 1 지역별 소비 · 부동산 데이터 통합 구축
 - 2 수도권 뚜벅이 여행지 경로 추천
 - 3 소득세법 RAG AI 챗봇
-

PROFILE

EDUCATION & CERTIFICATION

한림대학교 콘텐츠 IT 전공 / 인공지능 복수전공

자격증 : ADsP · SQLD · 리눅스마스터 2급

Technical Stack



Cloud & Infrastructure

AWS (EC2, S3, RDS, Lambda, IAM, VPC, Glue) · Linux



Data Engineering

Python · Spark · Kafka · Airflow · Iceberg



Database & Query

MySQL · Amazon Athena · SQL



Tools & Monitoring

Docker · Git · CloudWatch



Park Jimin

광고 Attribution Lakehouse 플랫폼 구축

개인 프로젝트 | Late Event 처리 · Medallion Architecture · 광고 KPI 데이터 파이프라인

프로젝트 배경

- 광고 이벤트의 발생 순서와 수집 순서 불일치
- Conversion 지연 도착으로 CVR·CPA 등 KPI 왜곡 가능
- Append 중심 처리만으로는 지연 이벤트를 기존 집계에 반영하기 어려움

핵심 목표

- 광고 이벤트 수집부터 KPI 집계까지 End-to-End 파이프라인 구축
- Late Event 반영을 통한 KPI 데이터 정확성 확보
- Raw → 정제 → KPI 집계까지 연결되는 Lakehouse 구축

핵심 설계


- Bronze · Silver · Gold Medallion Architecture 구성
- event_id 기반 Iceberg MERGE INTO Upsert 처리
- Late Event 도착 시 기존 데이터 갱신 및 KPI 재집계
- Airflow 기반 Merge · Aggregation · Maintenance 자동화

사용 기술 스택

INGESTION	 kafka
PROCESSING	 Spark
STORAGE / TABLE	 Amazon S3  ICEBERG
CATALOG / QUERY	 glue  athena
ORCHESTRATION	 Apache Airflow
VISUALIZATION	 Superset
INFRASTRUCTURE	 docker

전체 시스템 아키텍처

Kafka · Spark · Iceberg 기반 Medallion Architecture



Architecture Highlights

✓ Real-time Streaming Pipeline

Kafka + Spark Structured Streaming 기반
광고 이벤트 실시간 수집 및 처리

Late Event Handling

Spark Batch MERGE + Iceberg 기반
지연 이벤트 반영 및 데이터 갱신

Medallion Architecture

Bronze → Silver → Gold 단계별
원천·정제·집계 데이터 계층화

Late Event 처리를 통한 데이터 정합성 확보

지연 도착 이벤트로 인한 KPI 왜곡 → Iceberg MERGE 기반 보정

01 Problem Late Event 발생

Conversion 이벤트 지연 도착 시
기존 KPI 집계에서 누락될 수 있음

 Impression (실시간)



 Click (실시간)



 Conversion (지연 도착)

 KPI 왜곡 발생
CVR / CPA 등 주요 지표가 실제보다 낮게 집계

02 Solution MERGE 기반 보정 처리

최근 N일 범위의 데이터를 재처리하여
지연 이벤트를 반영하고 중복 방지

 Bronze 최근 N일 데이터 조회
지연 이벤트 포함한 일부 이벤트 조회



 event_id 기준 Deduplication
event_id 기준 중복 제거를 중복 처리 방지



 Iceberg MERGE
기존 데이터는 UPDATE, 신규 데이터는 INSERT



 Silver UPDATE / INSERT
정합성 있는 클린 데이터 유지

03 Result KPI 정합성 보장

지연 이벤트가 Silver에 반영되고,
Gold에서 KPI가 정확하게 재집계

 Late Event 반영
지연 도착 이벤트 Silver 업데이트



 Silver 정합성 확보
정확하고 중복 없는 데이터 유지



 Gold 재집계
월/캠페인 단위 KPI 재집계



 CTR / CVR / CPA 보정
정확한 KPI 산출 및 분석 가능

Medallion Architecture 기반 데이터 계층 설계

원천 → 정제 → 집계 단계별 데이터 역할을 분리하여 정합성과 활용성 확보

BRONZE Raw Data

원본 이벤트 그대로 보존하는 계층



Kafka
3 Topics

(impressions / clicks / conversion)



Spark Structured
Streaming

실시간 이벤트 수집



Amazon S3 (Parquet)
s3://ad-lakehouse/...

ad-attribution/bronze/{event}

데이터 예시

	kafka_partition	kafka_offset	kafka_timestamp	event_id	event_type	timestamp	event_time	uid	campaign
0	0	334329	2026-06-22 16:49:16.256	evt_00334329	impression	1780486295	2026-06-03T20:31:35	29232400	5084322
1	0	334330	2026-06-22 16:49:16.259	evt_00334330	impression	1780486296	2026-06-03T20:31:36	29986508	25998432
2	0	334331	2026-06-22 16:49:16.261	evt_00334331	impression	1780486297	2026-06-03T20:31:37	1954387	3073302
3	0	334332	2026-06-22 16:49:16.268	evt_00334332	impression	1780486300	2026-06-03T20:31:40	7241141	17321082
4	0	334333	2026-06-22 16:49:16.273	evt_00334333	impression	1780486302	2026-06-03T20:31:42	29002587	26091094
5	0	334334	2026-06-22 16:49:16.277	evt_00334334	impression	1780486303	2026-06-03T20:31:43	3017541	11042365

SILVER Cleaned Data

정제 및 정합성 확보된 이벤트 데이터 계층



Spark Batch
최근 N일 데이터 처리

예: 7-day window



event_id 기반
Deduplication



Late Event MERGE
UPDATE / INSERT



Silver Table (Iceberg)
정합성 있는 이벤트 데이터

- 데이터 검증 및 정제
- event_id 기준 Deduplication
- Late Event MERGE 반영

데이터 예시

event_id	event_date	uid	campaign	click	conversion	conversion_delay_sec	cost	updated_at
evt_00732965	2026-06-16	8333269	8403848	0	0		1.0E-5	2026-06-23 06:21:50.291949 UTC
evt_00732968	2026-06-16	2748331	26998434	1	0		6.67867765707E-5	2026-06-23 06:21:50.291949 UTC
evt_00732981	2026-06-16	20771428	32323516	0	0		3.784131952E-5	2026-06-23 06:21:50.291949 UTC
evt_00732982	2026-06-16	24792525	10341182	1	0		6.49894641857E-5	2026-06-23 06:21:50.291949 UTC
evt_00732996	2026-06-16	19851709	8634899	1	0		8.69819464953E-4	2026-06-23 06:21:50.291949 UTC
evt_00733002	2026-06-16	26246791	23330020	0	0		6.49820535174E-4	2026-06-23 06:21:50.291949 UTC
evt_00733004	2026-06-16	29871331	24378636	1	0		4.01893865884E-5	2026-06-23 06:21:50.291949 UTC
evt_00733005	2026-06-16	1769551	31129938	1	0		3.57352950994E-4	2026-06-23 06:21:50.291949 UTC
evt_00733013	2026-06-16	3537577	30729721	0	0		4.64168103303E-5	2026-06-23 06:21:50.291949 UTC

GOLD Aggregated Data

비즈니스 분석을 위한 집계 데이터 계층



Spark Aggregation
Silver 데이터 기반 집계 처리



Gold Table (Iceberg)
일/캠페인 단위 KPI 집계 데이터

- 일 / 캠페인 단위 KPI 집계
- CTR / CVR / CPA 산출
- Athena / Superset 활용

데이터 예시

summary_date	campaign	impressions	clicks	conversions	total_cost	ctr	cvr	cpa
2026-06-16	73325	5	2	2	6.932824757372E-4	40.0	100.0	3.466412378686E-4
2026-06-16	73327	17	4	1	0.0010258692611788002	23.52941176470588	25.0	0.0010258692611788002
2026-06-16	73328	21	9	5	0.0030223681097864006	42.85714285714286	55.55555555555556	6.044736219572801E-4
2026-06-16	83677	92	25	0	0.027998312874257792	27.17391304347826	0.0	
2026-06-16	289466	27	11	1	0.006039088143868801	40.74074074074074	9.09090909090909	0.006039088143868801
2026-06-16	336258	3	2	0	5.677810089474E-4	66.66666666666667	0.0	
2026-06-16	408759	25	10	3	0.002241736236477	40.0	30.0	7.472445412159E-4
2026-06-16	442617	26	5	0	0.004826205477074	19.23076923076923	0.0	

농산물 시장 종합 모니터링 대시보드

5인 팀 프로젝트 | 담당 - 기상 데이터 ETL · 공급 위험 예측 모델링 · QuickSight 대시보드 구축

프로젝트 배경

- 이상기후로 농산물 공급 변동성 증가
- 시장·기상 데이터가 분산되어 통합 분석에 한계
- 데이터 기반 공급 위험 모니터링 필요

핵심 목표

- 기상·경매 데이터 통합 파이프라인 구축
- 공급 감소 위험 조기 탐지
- BI Dashboard 기반 모니터링 환경 구축

주요 담당 역할


- 기상 API 데이터 수집·ETL 파이프라인 구현
- 공급 감소 위험 예측 모델 개발
- Athena 기반 분석 데이터 구성
- QuickSight 대시보드 구축

사용 기술 스택


s3


Lambda


EventBridge


Glue


Athena



Python


QuickSight


Sagemaker

전체 시스템 아키텍처

데이터 수집부터 저장 · 분석 · 시각화까지의 전체 흐름



Architecture
Highlights

Batch + Streaming

하이브리드 수집 체계

Medallion Architecture

단계별 데이터 품질 관리

Serverless ETL

AWS Glue 기반 자동화

Athena Analytics


Athena 기반 SQL 분석

BI Dashboard

QuickSight 시각화

기상 데이터 ETL Pipeline (Batch)

기상 데이터 수집부터 정제, 가공까지의 배치 ETL 프로세스



Gold Layer 데이터 모델링

Star Schema 기반 분석 데이터 마트 설계

Gold Layer 구조

Fact Table

거래/공급량 중심
핵심 지표 보관



Dimension


분석 기준 정보
마스터 데이터



Star Schema

조인 최소화
조회 성능 최적화

Star Schema ERD (Gold Layer)



주요 Gold Layer 테이블

테이블명	유형	테이블 설명
fact_trade	Fact	거래 및 공급 관련 핵심 지표
dim_market	Dimension	시장 정보
dim_origin	Dimension	산지(출하지) 정보
dim_product	Dimension	품목 및 분류 정보
dim_date	Dimension	날짜 정보 (연/월/일)
dim_grade	Dimension	등급 정보

핵심 설계 포인트

쿼리 최적화

Fact-Dimension 구조 기반 분석
쿼리 단순화

BI Dashboard

QuickSight 분석을 위한 데이터
마트 구성

ML Feature

ML 학습용 Feature 제공

확장성

신규 데이터·지표 확장을 고려한
Dimension 구조

ML 기반 공급 감소 위험 탐지 모델링

기상 스트레스 임계치 분석을 통한 공급 감소 위험 탐지 및 의사결정 모델

1 문제 정의의 전환

기존 접근

Regression (공급량 예측)

정확한 수치 예측의 실효성 한계



개선 방향

Risk Detection (공급 감소 위험 탐지)

공급 위험 여부를 판단하는 문제로 재정의

☑ 의사결정에 활용 가능한 위험 신호 제공

2 Feature Engineering (생육기 기반)

씨뿌림기

D-60 ~ D-40



아주심기

D-40 ~ D-20



수확·결구기

D-20 ~ D-5

기상 Stress 기반 요약 Feature



Temperature Stress



Rainfall Stress



Sunlight Stress

3 Hybrid ML Pipeline (위험 탐지 프로세스)

Feature
생성



Ridge

(영향 요인 분석)



RandomForest

(비선형 위험 탐지)



Rule 생성

(조건기반 위험 판단)



Risk Score
산출

위험 등급 산출

● Stable (안정)

● Caution (주의)

● Risk (위험)

특정 위험 조건 n개 이상 충족 시 공급 감소 위험으로 판단

⊕ 핵심 설계 포인트

영향 요인 분석

Ridge 활용
영향 요인 분석

Rule 기반 위험 판단

도메인 지식 반영
조건 기반 위험 탐지

생육기 기반 Feature

기상 Stress 반영

Dashboard 연계

위험도 시각화 및
의사결정 지원

👤 주요 담당 역할

- ✓ Feature Engineering 및 Stress Feature 생성
- ✓ Ridge 기반 기상 영향 요인 분석
- ✓ RandomForest 기반 공급 감소 위험 탐지 모델 구현
- ✓ Rule 기반 Risk Score 설계 및 Dashboard 연계



데이터 기반 의사결정 지원 대시보드

QuickSight 대시보드 화면 구성


지역별 공급 감소 위험 등급 예측 및 Heatmap



연도별 생육기 기상 패턴 비교 분석





2 실시간 경매 모니터링 대시보드



실시간 경매 현황 및 위험 신호 모니터링



출하 공급량 및 가격 흐름 분석



주요 분석 목적별 화면 구성

S3 기반 데이터 SQL 분석

대시보드 조회 성능 개선

KPI · 위험도 ·
지역별 분석

🔄 전체 대시보드 & 상세 문서 확인

GitHub Repository

<https://github.com/jimin-park-01/agricultural-market-monitoring-dashboard.git>

README → Dashboard Overview 참고

3-Tier 인프라 환경 구축

5인 팀 프로젝트 | 담당 - AWS 인프라 설계 · Auto Scaling 검증 · 모니터링 구축

프로젝트 배경

- 중소기업 웹 서비스 운영 환경 가정
- 안정적인 서비스 운영을 위한 고가용성 인프라 필요
- 단일 서버 구조의 장애 · 확장성 한계

핵심 목표

- Multi-AZ 기반 고가용성 환경 구축
- Auto Scaling 기반 트래픽 대응
- 모니터링 및 부하 테스트를 통한 안정성 검증

주요 담당 역할

- IAM 정책 및 권한 설계
- VPC · EC2 · RDS 인프라 구축
- Apache Reverse Proxy 구성
- ALB · NLB 구성 및 연동
- CloudWatch 모니터링 · AutoScaling · k6 부하 테스트

사용 기술 스택

CLOUD

EC2 RDS

NETWORK

VPC ALB NLB

Security



IAM

Monitoring



CloudWatch


Test



K6

3-Tier 아키텍처설계

고가용성, 확장성, 운영 효율성을 고려한 AWS 기반 3-Tier 인프라 구성



Design Decisions

왜 이렇게 설계했는가?

선택 (What)	설계 내용	선택 이유 (Why)
 Multi-AZ 고가용성 확보	• WEB · WAS를 Multi-AZ로 분산하고 RDS Multi-AZ 구성	✔ 장애 영향 최소화 ✔ 서비스 연속성 확보
 3-Tier 아키텍처 계층 분리	• WEB - WAS - DB 계층을 분리하여 역할과 책임을 명확히 분리	✔ 보안 강화 ✔ 확장성 및 유지보수 용이
 Auto Scaling 탄력적 확장	• 트래픽 변화에 따라 WEB · WAS 인스턴스 자동 확장/축소	✔ 부하 대응 ✔ 비용 효율화
 CloudFront + S3 Failover 장애 대응	• CloudFront에서 5xx 장애 감지 시 S3 정적 페이지로 자동 전환	✔ 장애 대응 ✔ 사용자 경험 보호
 보안 강화 안전한 접근 및 정보 보호	• Private Subnet · Security Group · IAM · Secrets Manager 기반 접근 제어	✔ 외부 노출 최소화 ✔ 접근 통제 및 권한 관리
 운영 자동화 및 모니터링 운영 효율성	• CloudWatch 모니터링 및 알림으로 장애를 빠르게 감지하고 대응	✔ 장애 조기 탐지 ✔ 운영 가시성 확보

보안 그룹 설계 (Security Group)

최소 권한 원칙 (Least Privilege)에 기반한 계층 간 통신 제어

통신 흐름

Internet

↓ 80 / 443

1	ALB (SG-ALB)	Inbound Allow	Port 80, 443	Source 0.0.0.0/0
---	-----------------	------------------	-----------------	---------------------

↓ HTTP : 80

2	WEB EC2 (SG-WEB)	Inbound Allow	Port 80 (TCP)	Source SG-ALB
---	---------------------	------------------	------------------	------------------

↓ TCP : 8080

3	Internal NLB (SG-NLB)	Inbound Allow	Port 8080 (TCP)	Source SG-WEB
---	--------------------------	------------------	--------------------	------------------

↓ TCP : 8080

4	WAS EC2 (SG-WAS)	Inbound Allow	Port 8080 (TCP)	Source SG-NLB
---	---------------------	------------------	--------------------	------------------

↓ TCP : 3306

5	RDS MySQL (SG-RDS)	Inbound Allow	Port 3306 (TCP)	Source SG-WAS
---	-----------------------	------------------	--------------------	------------------

Security Highlights

Internet → ALB만 공개
외부에서는 ALB의 80/443 포트만 접근 허용

WEB / WAS / DB
모두 Private Subnet 배치
외부 직접 접근 불가

Security Group Reference 기반 통신
IP 대신 보안 그룹 참조로 통신 제어

Session Manager 사용
SSH Port(22) 미사용으로 보안 강화

운영 고도화 핵심 서비스

운영 효율성과 보안 강화를 위한 AWS 관리형 서비스



Session Manager

Bastion Host 제거 및 안전한 접근

- ✓ Bastion Host 없이 EC2에 안전하게 접속
- ✓ SSH Port(22) 미사용으로 보안 강화
- ✓ 접속 세션 및 명령 로그 관리



Secrets Manager

민감 정보의 안전한 관리

- ✓ RDS 계정 등 민감정보 안전하게 관리
- ✓ WAS 환경변수 및 외부 API 키 관리
- ✓ 애플리케이션 코드와 민감정보 분리



CloudFront Failover

장애 발생 시 정적 페이지 전환

- ✓ 정상 요청은 ALB로 전달
- ✓ 5xx 오류 감지 시 S3 정적 페이지로 전환



CloudWatch

모니터링 및 자동 확장 지원

- ✓ 주요 리소스 지표 모니터링
- ✓ Auto Scaling을 위한 지표 모니터링 및 알람 구성
- ✓ 로그 수집 및 알림으로 장애 대응 강화

성능 검증 및 결과

트래픽 폭주 상황에서의 자동 확장성 및 서비스 안정성 검증 (Tool: k6 + CloudWatch)



TEST SCENARIO

이벤트성 트래픽 폭주가정

서비스 중단 없는 확장성 검증

AVG RESPONSE

0.15s

P95 RESPONSE

0.38s



목표치(0.5s) 이내 달성

TOTAL REQUESTS

6.6M



Max VUs: 600 / Error: 0.00%

1 Auto Scaling 동작 검증





부하 증가에 따라 WAS 인스턴스가 자동 확장되었으며,
이후 응답 시간이 감소하는 패턴 확인

2 WEB 리소스 부하 검증



부하 증가 시 cpu와 Network I/O가 함께 증가하고,
종료 후 감소하는 패턴 확인

3 WAS 부하 및 Alarm 검증



WAS CPU 70% 이상 구간에서 CloudWatch Alarm이 발동하고,
부하 종료 후 지표 감소 확인

부하테스트 실행 및 결과 (Loda Test)

k6 부하 테스트 진행 과정 및 최종 결과 리포트

Environment

AWS EC2 (t4g.small) x 4
k6 Load Generator & Target Servers

Real-time Monitoring

ubuntu@ip-192-168-1-224:~\$ k6 run test.js



execution: local
script: test.js
output: -

scenarios: (100.00%) 1 scenario, 600 max VUs, 42m30s max duration (incl. graceful stop):
* default: Up to 600 looping VUs for 42m0s over 7 stages (gracefulRampDown: 30s, gracefu
lStop: 30s)

0[||||| 13.4%] Tasks: 57, 599 thr, 10
1[||||| 1.3 16.3%] Load average: 0.25 0.0
Mem[||||| 322M/1.80G] Uptime: 05:38:57
Swp[0K/0K]

Main I/O

PID	USER	PRI	NI	VIRT	RES	SHR	S
7926	root	20	0	1216M	26352	13400	S
12590	apache	20	0	1533M	9748	5616	S
12485	apache	20	0	1533M	9600	5620	S
8219	root	20	0	1216M	26352	13400	S
7929	root	20	0	1216M	26352	13400	S
8045	root	20	0	234M	7408	6128	S
7928	root	20	0	1216M	26352	13400	S

0[||||| 11.5%] Tasks: 54, 582 thr, 110
1[||||| 15.0%] Load average: 0.12 0.06
Mem[||||| 280M/1.80G] Uptime: 05:36:56
Swp[0K/0K]

Main I/O

PID	USER	PRI	NI	VIRT	RES	SHR	S	CPU
7809	root	20	0	1215M	26108	13160	S	8.
11952	apache	20	0	1533M	10100	5672	S	2.
7814	root	20	0	1215M	26108	13160	S	2.
7831	root	20	0	1215M	26108	13160	R	2.
11786	apache	20	0	1694M	9756	5612	S	2.
7811	root	20	0	1215M	26108	13160	S	1.
7817	root	20	0	1215M	26108	13160	S	1.

1 k6 부하테스트 실행 (100 → 600 VUs Ramp-up) 및 WEB / WAS 서버의 실시간 리소스 모니터링

Final Report

HTTP

http_req_duration.....: avg=150.99ms min=5.6ms med=104.09ms max=1m0s p(90)=312.76ms p(95)=375.36ms
{ expected_response:true }....: avg=150.96ms min=5.6ms med=104.09ms max=45.94s p(90)=312.76ms p(95)=375.36ms
http_req_failed.....: 0.00% 3 out of 6625878
http_reqs.....: 6625878 2629.315281/s

2 최종 테스트 결과 평균 응답 시간 0.15s , P95 응답 시간 0.38s 기록 / 약 662만 건의 요청에서 에러율 0.00% 확인

지역별 소비·부동산 데이터 통합 구축

개인 프로젝트 | 데이터수집·전처리·통합 및 분석 데이터셋 구축

프로젝트 배경

- 관광 출처가 다른 소비·부동산데이터의 지역/시간 기준이 서로 다름
- 전국 평균 데이터와 경기 지역 데이터가 혼재되어 정합성 확보 필요
- 분석 이전에 활용 가능한 형태의 통합 데이터셋 구축이 필요

핵심 목표

- 공공데이터 수집 및 정합성 검토
- 지역코드 매핑 및 기간 단위 정규화
- 분석 가능한 소비·부동산 통합 데이터셋 구축

핵심 설계

- 데이터 수집 및 전처리
- 법정동/행정구역 코드 기준 매핑
- 결측치 단위 불일치 정리 및 파생 변수 생성
- 통합 데이터 검증 및 기초 시각화 지원

사용 기술 스택

DATA SOURCE
통계청, 경기데이터드림, 한국부동산원

DATA PROCESSING
Python, Pandas, Numpy

ANALYSIS & VISUALIZATION
Correlation Analysis,
Seaborn, Matplotlib

공공데이터 정규화 및 통합 데이터셋 구축

서로 다른 지역·시간 기준 정규화 통해 소비·부동산 통합 데이터 구조로 통합



1. Raw Data

- 통계청 가계지출
- 경기 카드소비 데이터
- 한국부동산원 매매·전세 지수
- 법정동 · 행정구역 코드
- 생활이동 / 유동인구



2. Cleaning & Standardization

- 결측치 · 이상치 정리
- 컬럼명 / 데이터 타입 통일
- 월 · 연도 기준 정규화
- 지역명 형식 정리



3. Mapping & Integration

- 행정구역 코드 매핑
- 지역 · 기간 Key 기준 결합
- 지역 단위 정합성 확보
- 파생 변수 생성



4. Analysis Dataset

- 지역 x 기간 기준 통합 테이블
- 소비 + 부동산 + 지역특성 변수
- 상관분석 · 시각화 활용 가능
- 분석용 데이터셋 완성



핵심 처리 포인트

- 지역 단위 불일치 해결
- 시간 기준 통일
- 분석용 공통 스키마 구축



최종 산출물


지역	연도	분기	구분	소비금액	소비금액(억)	소비금액(억표시)	매매지수
경기도 수원시	2022	1	전체	2.004439e+12	20044.4	20,044.4 억원	180.9
경기도 화성시	2022	1	전체	2.003832e+12	20038.3	20,038.3 억원	170.4
경기도 용인시	2022	1	전체	1.954644e+12	19546.4	19,546.4 억원	185.4
경기도 수원시	2022	1	생활형	1.746545e+12	17465.4	17,465.4 억원	180.9
경기도 용인시	2022	1	생활형	1.693724e+12	16937.2	16,937.2 억원	185.4
...	...	...	...	...	...	...	...
경기도 포천시	2024	4	기타	4.610554e+10	461.1	461.1 억원	109.6
경기도 안양시	2024	4	비생활형	4.370677e+10	437.1	437.1 억원	152.8
경기도 포천시	2024	4	비생활형	3.157411e+10	315.7	315.7 억원	109.6
경기도 하남시	2024	4	비생활형	2.561244e+10	256.1	256.1 억원	166.7
경기도 광명시	2024	4	비생활형	2.065456e+10	206.5	206.5 억원	164.6

분석 가능한 통합 데이터셋


통합 데이터 검증 및 분석 활용

구축한 통합 데이터셋 기반 지역별 소비와 부동산 지표 관계 검증


01 상관관계 요약



02 시계열 추세 비교



03 추가 검증 결과



Key Achievement

지역 · 기간 기준 데이
터 결합 검증 완료

소비 · 부동산 지표 간
비교 분석 가능

상관관계 및
추세 분석 수행

실제 분석에 활용 가능한
통합 데이터셋 확보

수도권 두박이 여행지 경로 추천

4인 팀 프로젝트 | 데이터수집 및 전처리, 관광지수 산출 및 모델링, 시각화담당

프로젝트 배경

- 관광 데이터 증가 추세 대비 맞춤형 정보 부족
- 대중교통 이용 수요를 고려한 접근성 기반 여행지 추천 필요

핵심 목표

- 관광/인구/교통/리뷰 데이터 통합 분석
- 지역별 최적 여행지 분류 및 혼잡도 회피
- 사용자 선호 기반 맞춤형 여행 경로 추천

주요 담당 역할

- 데이터 수집 및 전처리
Tour API, 대중교통 데이터 정제
- 지수 산출 및 모델링
공간 가중 행렬, 클러스터링 활용
- 추천 알고리즘 개발
사용자 맞춤형 경로 추천 로직 구현
- 시각화 및 결과 제시
지도 기반 데이터 시각화

사용 기술 스택

DATA SOURCE

Tour API, 공공데이터, 교통카드, 카카오맵 API, 카카오 리뷰

DATA PROCESSING


Python, Pandas, NumPy, Haversine, Spatial Weight Matrix

ML & VISUALIZATION


K-means, PCA, Factor Analysis, Folium, Matplotlib

데이터 분석 및 추천 Pipeline

데이터 수집부터 추천 결과 제공까지의 전체 흐름



6개 핵심 지수 설명



분석 결과 및 서비스

데이터 분석을 통해 도출된 인사이트를 기반으로 사용자 맞춤 여행지 추천

**4**

Data Sources

Tour API · 교통데이터 리
뷰 데이터 · 공공데이터

**6**

Feature Indices

관광 · 접근성 · 혼잡도
감성 · 인기 · 다양성



PCA + K-Means Analysis Model

차원 축소 및 관광지 유형
군집화 분석



Top-10 Recommendation


사용자 조건 기반
추천 결과 제공

01 지수 분석 및 군집화

[클러스터별 대표 행동동-카테고리 top3]

cluster	행정구	행정동	카테고리	avg_rating	review_count	positive_ratio
0	경기 양주시	양주1동	음식	3.875000	104.0	0.461538
0	경기 가평군	조종면	음식	3.802083	96.0	0.468750
0	경기 고양시	장항1동	음식	3.771429	105.0	0.485714
1	서울 중랑구	망우본동	힐링	4.411765	17.0	0.588235
1	서울 양천구	신정6동	힐링	4.368421	19.0	0.578947
1	서울 노원구	공릉1동	문화	4.500000	14.0	0.571429
2	경기 양평군	강상면	액티비티	3.294118	17.0	0.294118
2	경기 군포시	영화동	음식	3.375000	16.0	0.312500
2	경기 광명시	철산1동	음식	3.250000	16.0	0.312500

[카테고리별 클러스터 분포 비율]



클러스터 1

대중적인 인기 음식 지역

클러스터 2



소규모 고 평가 힐링 / 문화 공간

클러스터 3

관심도 / 만족도 모두 낮은
쇼핑 / 액티비티 위주의 비인기 지역


6개 지수를 종합하여 관광지 유형을 3개 클러스터로
군집화하고 특성 해석

02 PCA 기반 관광지 특성 분석



PCA로 관광지 특성을 축소하고 K-Means로 유사 관광지
군집을 3개 유형으로 분류

03 맞춤형 여행지 추천 서비스 (실제 결과)



사용자 지역 / 테마 / 선호도를 반영하여 TOP-N 추천 및
추천 장소별 인기도 정보, 이동거리, 시간대별 혼잡도 제공



Key Achievement

4개의 이기종 데이터를 통합하여
분석 가능한 데이터로 구축

6개 핵심 지수를 설계하고 관
광지 특성 및 혼잡도 정량화

PCA로 차원 축소 후 K-Means로
관광지 유형 3개 군집화

사용자 맞춤형 추천 서비스 구현
및 시간대별 혼잡도 정보 제공

소득세법 RAG AI 챗봇

| 개인 프로젝트 | RAG 기반 법령 질의응답 구현

 프로젝트 배경

- LLM의 외부 문서 활용을 위한 RAG 구조 학습
- 소득세법을 활용한 법령 질의응답 서비스 구현

 핵심 목표

- 법령 문서를 Vector DB에 구축하고 관련 조문 검색
- 검색된 문서를 근거로 LLM 답변 생성
- 일상 표현과 대화 맥락을 반영한 질의응답 구현

 핵심 설계

- 문서 전처리 및 임베딩
(DOCX → Chunking → Embedding)
- Query Transformation
(일상 표현 → 법률 검색 용어 변환)
- History-aware Retrieval
(이전 대화 맥락을 반영한 문서 검색)
- RAG Chat UI
(검색 문서 기반 답변 및 Streaming 출력)

 사용 기술 스택

- RAG / LLM
- LangChain, OpenAI, OpenAI Embedding
- VECTOR DB
- Pinecone
- APPLICATION
- Streamlit, Python

분석 결과 및 서비스

문서 전처리와 질의 변환을 적용한 소득세법 기반 RAG 챗봇 구현

법령 문서 전처리

→ DOCX 로딩 과정에서 세율표 추출 X

→ 표 구조를 Markdown 형태로 변환해 검색 가능한 문서로 구성

종합소득 과세표준	세 율
1,400만원 이하	과세표준의 6퍼센트
1,400만원 초과 5,000만원 이하	84만원 + (1,400만원을 초과하는 금액의 15퍼센트)
5,000만원 초과 8,800만원 이하	624만원 + (5,000만원을 초과하는 금액의 24퍼센트)
8,800만원 초과 1억5천만원 이하	1,536만원 + (8,800만원을 초과하는 금액의 35퍼센트)
1억5천만원 초과 3억원 이하	3,706만원 + (1억5천만원을 초과하는 금액의 38퍼센트)
3억원 초과 5억원 이하	9,406만원 + (3억원을 초과하는 금액의 40퍼센트)
5억원 초과 10억원 이하	1억7,406만원 + (5억원을 초과하는 금액의 42퍼센트)
10억원 초과	3억8,406만원 + (10억원을 초과하는 금액의 45퍼센트)



종합소득 과세표준	세 율
1,400만원 이하	과세표준의 6퍼센트
1,400만원 초과 5,000만원 이하	84만원 + (1,400만원을 초과하는 금액의 15퍼센트)
5,000만원 초과 8,800만원 이하	624만원 + (5,000만원을 초과하는 금액의 24퍼센트)
8,800만원 초과 1억5천만원 이하	1,536만원 + (8,800만원을 초과하는 금액의 35퍼센트)
1억5천만원 초과 3억원 이하	3,706만원 + (1억5천만원을 초과하는 금액의 38퍼센트)
3억원 초과 5억원 이하	9,406만원 + (3억원을 초과하는 금액의 40퍼센트)
5억원 초과 10억원 이하	1억7,406만원 + (5억원을 초과하는 금액의 42퍼센트)
10억원 초과	3억8,406만원 + (10억원을 초과하는 금액의 45퍼센트)

Query Transformation

→ 일상 표현과 법률 용어의 차이 고려

→ Dictionary 기반으로 검색 질의를 변환

```
dictionary = [
    "일상적인 사람 표현과 관련된 표현 -> 거주자",
    "독립적으로 일을 제공하여 얻는 소득을 나타내는 표현 -> 사업소득"
]
```

RAG Chatbot Demo

소득세법 AI 챗봇

소득세에 관한 궁금증을 쉽고 명확하게 답변드립니다!

소득세법 AI 챗봇

소득세에 관한 궁금증을 쉽고 명확하게 답변드립니다!

연봉 5천만원인 회사의 소득세는?

소득세법 제55조(세율)에 따르면, 연봉 5천만원인 회사의 소득세는 다음과 같이 계산됩니다.

과세표준 1,400만원 초과 5,000만원 이하 구간에 해당하므로, 소득세는 84만원 + (1,400만원을 초과하는 금액의 15퍼센트)를 계산하여 산출합니다.

따라서 소득세는 84만원 + (3,600만원 × 0.15)로 계산되며, 총 624만원이 됩니다.

그럼 1억원은 ?

소득세법 제55조(세율)에 따르면, 연봉 1억원인 경우의 소득세는 다음과 같이 계산됩니다.

과세표준 8,800만원 초과 1억5천만원 이하 구간에 해당하므로, 소득세는 1,494만원 + (8,800만원을 초과하는 금액의 35퍼센트)로 계산됩니다.

따라서, 소득세는 1,494만원 + (1,200만원 × 0.35)로 계산되며, 총 1,914만원이 됩니다.

프리랜서로 일해서 번 돈은 소득세를 어떻게 계산해야 할까?

소득세법 제55조(세율)에 따르면, 거주자의 사업소득은 종합소득의 일부로 계산되고, 해당 연도의 종합소득과세표준에 해당하는 세율을 적용하여 소득세를 계산합니다.

세율은 과세표준 구간에 따라 6%부터 최대 45%까지 차등 적용되며, 각 구간에 맞게 계산하여 소득세를 산출해야 합니다.

개인적으로 외주 일을 해서 번 돈은 소득세를 어떻게 계산해야 할까?

소득세법 제55조(세율)에 따르면, 거주자가 독립적으로 일을 제공하여 얻는 사업소득은 종합소득의 일부로 간주되고, 해당 연도의 종합소득과세표준에 적용되는 세율을 기반으로 소득세를 계산합니다.

과세표준 구간에 따라 6%에서 45%까지의 차등 세율이 적용되며, 각 구간에 맞춰 계산하여 총 소득세를 산출합니다.

무엇이 궁금하신가요?



THANK YOU

CONTACT

010-2627-8418

qwa8418@naver.com